

2021 年度卒業論文

サッカーの実試合データのグラフ化  
によるパスコースの予測

法政大学理工学部

応用情報工学科

インタラクティブ・システム研究室

学籍番号 18X3002

阿部大輝

## 概要

近年、スポーツにおいても、選手やチームのデータ分析が重要となっており、それを専門とする企業やスポーツアナリストという職業も存在する。本研究ではチームスポーツの例としてサッカーを取り上げ、実試合の中から得られるデータをもとにパスコースの予測を行うことを目標とする。

先行研究としては、糸田らが統計学の手法であるロジスティック回帰モデルを利用した予測を提案し、約8割の精度を実現した。しかし予測の際に時間的な前後関係は考慮されていないこととボールの周囲にいる選手のみ予測の対象にしており、限定的な予測となっている。

この問題点を解決すべく、本論文では Graph Convolution を用いて、予測を行う手法を提案する。

Graph Convolution は EC サイトなどにおけるレコメンドシステムや分子構造からの物性推定などの分野で成果を上げており、近年注目されている技術である。Graph Convolution を用い、試合におけるパスの流れを選手をノード、パスをエッジとするグラフを構築することで予測を行う。また先行研究において課題であった時間的な前後関係を含んだ予測が行うために、Spatial Temporal Graph Convolutional Networks のグラフ構造を模したグラフ構造を提案し、それを用いた予測を行った。

# 目次

1	はじめに	3
2	提案手法	5
2.1	Relational-Graph Convolutional Networks . . . . .	6
3	グラフの定義	12
4	結果と考察	15
4.1	計 6 4 試合分のデータを用いた予測 . . . . .	15
4.2	Spatial Temporal Graph Convolutional Networks のグラフ 構造の適用 . . . . .	16
4.3	ラベル数の削減 . . . . .	19
5	まとめと今後の課題	20
	謝辞	21

# 1 はじめに

サッカーやバスケットなどのチームスポーツにおける戦術的アクション (パスやシュートなど) の予測は、試合を有利に進めるための重要な要素である。本来それらは、当事者である選手やコーチの経験や直感に基づいて行われるものであり、各個人の主観によるものである。チームの戦術を含む情報の客観的分析を行う立場としてスポーツアナリストという職業が存在し、客観的なデータを用いて戦術的アクションの予測やチームの方針の提案を行っている。スポーツアナリストは日本で注目され始めてから約 10 年のほどと短く、明確な定義が難しいが「選手及びチームを目標達成に導くために、情報戦略面で高いレベルでの専門性を持ってサポートする職業」と考えられている。現在、スポーツアナリストが主に分析の際、用いるのは統計分析であり、それは学術的研究におけるスポーツのアクション予測手法においても同様の傾向がある。先行研究の一つとして糸田らが提案した統計分析のアプローチであるロジスティック回帰分析を用いたパスレシーバーの予測手法 [1] を紹介する。

この研究では、パス行動のモデル化において、出力に対する不確定さを定量的に評価することが可能な確率的識別モデルであるロジスティック回帰モデルを用いる。またサンプルデータとして三試合分から抽出した選手のトラッキングデータの中から 100 本のパスの場面におけるボールの保持者とボールの周囲にいる選手 (敵味方各 3 人ずつ) の位置情報をサンプルデータとして抽出した。そのうちの 3 つを例として図 1 に示す。

パス行動を行う選手の視線から、パスを受ける味方選手を予測することができると考え、視線重みフィルター (図 2) を全選手に対して導入する。矢




図1 行動履歴から抽出した視線と位置関係

(ボールホルダーが中心となっており、○が味方選手、×が敵選手、●同士でパスをつないだ場面を表している。)

印方向を視線とし、24度ごとに重みをつける。これらは距離に対する重みであり、正面にいる選手の重みは小さくなり、重みを掛け合わせるにより、疑似的に実際の距離より近いものとして考えることができる。




図2 視線重みフィルター

さらに、味方選手の中から一人を選ぶ多クラス分類器と、味方選手一人ひとりに適応する2クラス分類器の2通りのモデルを設計し、評価を行った。

精度は多クラス分類器が約 94%、2 クラス分類器が約 75% という結果であった。

この研究では、パスを行う瞬間の周囲の状況（選手の位置や視線など）を数値化し、予測を行っているのでそれ以前にどのように選手やボールが動いたかなどの時間的な前後の状況は予測に含まれていない。しかし、実際の試合では時間経過により、戦略の変更を行ったり、状況の有利不利など、時間により変わる要素が存在する。

本研究では、これらの時間により変化する要素がパスなどの戦略的アクションに影響すると考え、ボールの一連の動きをグラフデータとみなすことで、パス前後の時間的な関係の情報とパスがどのようにつながっていくかの空間的情報を保持するデータを構築し、この問題点を解決することを目指す。

## 2 提案手法

本研究ではパスコースの予測手法として、サッカーの実試合から得られるデータを選手をノード、パスをエッジとしたグラフデータに変形し、グラフデータに対する深層学習手法である Relational-Graph Convolutional Networks(R-GCN)[2] を用いた手法を提案する。

データ構造におけるグラフとは、ノード (頂点) とノード間の連結を表すエッジ (枝) によって構成されるデータ型 (図 3) である。一般的にグラフ  $G$  は、ノードの集合  $V$  とエッジの集合  $E$  を用いて、 $G = (V, E)$  と表され、近年、グラフデータベースの発展により、注目されているデータ構造である。




図3 グラフデータ構造

## 2.1 Relational-Graph Convolutional Networks

Graph Convolution という技術は画像や映像の認識、分類などに使われる Convolution Neural Network(CNN)[3] のアイデアをもとに、グラフに適応可能な形へ拡張したものであり、EC サイトのレコメンドシステムや化合物の物性予測などに利用されている。Graph Convolution という手法は様々な拡張がなされており、今回はその中でより直感的でエッジが方向を持つ有向グラフに適応可能なモデルである Relational-Graph Convolutional Networks(R-GCN)[2] を用いる。

R-GCN[2] は、グラフの中でも、エッジが方向を持つ有向グラフに対応することができる学習モデルであり、ナレッジベースなどにおいて、欠落した情報の補完を一つの目的としている。ナレッジベースは知識を整理して保存し、素早い情報検索を行うためのものであり、そのメンテナンスに多大な労力が費やされているのにもかかわらず、最大規模のもの (Yago、DBPedia など) でさえいまだ不完全なものであり、接続関係など欠落した情報が存在するとされている。その情報の欠如がナレッジベースを利用するアプリケーションに影響を及ぼしている。

Schlichtkrull[2] らが提案した手法では、ナレッジベースに含まれている情報は、RDF の記述に用いられるデータ形式であるトリプル (図 4) にて定義できると仮定し、トリプルをノードとエッジにあてはめたラベル付き有向マルチグラフとして考えることができるとした。



図 4 トリプル

知識ベースの例として、図 5 のようなトリプルについて考える。図 5 では Mikhail Baryshnikov という主語と Vaganova Academy という目的語を educated at という述語でつないでいるトリプルが存在している。今回欠落した情報を補完するためにグラフのリンク予測 (欠落したトリプルの予測) とノード分類 (ノードに対するラベルの割り当て) について考える。例えば、Mikhail が Vaganova Academy (バレエ学校) へ通っていたことはこの人物がバレエダンサーであることを推測させ (ノード分類)、そして Vilcek prize (アメリカ社会に貢献した移民に送られる賞) を受賞したことは、アメリカに在住していることを推測 (リンク予測) させるのに十分な情報である。Schlichtkrull[2] らは、このようにナレッジベースに存在する情報は、周囲の情報を参照することで推測できるという直感をもとに R-GCN モデルの開発を行った。

R-GCN で対象とするグラフは、 $G = (V, E, R)$  とされ、各ノード  $v_i \in V$ 、



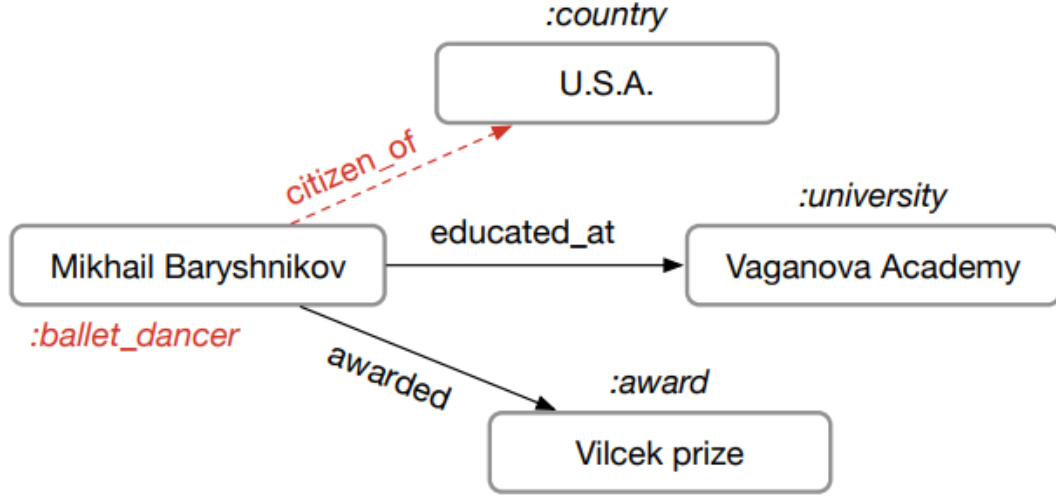


図5 知識ベースの一部

(例えば、educated at はエッジにおけるラベル、:university はノードにおけるラベルでを表しており、赤色で記述されている部分は本来、欠落している情報を表している)

エッジの各ラベル  $r \in R$ 、ラベル付きのエッジ  $(v_i, r, v_j) \in E$  として表現され、グラフ  $G$  はループ、多重エッジ、有向エッジを含む有向マルチグラフであり、各ノード  $v_i$  はそれぞれラベルと特徴量を持つ。複数の R-GCN 層のうち、ある一層におけるノード  $v_i$  の次の層に対する順伝搬は式 (1) のように定義される。

$$h_i^{(l+1)} = \sigma \left( \sum_{r \in R} \sum_{j \in N_i^r} \frac{1}{c_{i,r}} W_r^{(l)} h_r^{(l)} + W_0^{(l)} h_i^{(l)} \right) \quad (1)$$

式 (1) において  $h_i^{(l)}$ 、 $W_r^{(l)}$  は、それぞれ  $l$  層目におけるノード  $v_i$  の特徴量と重みを表し、重みはエッジのラベル  $r$  ごとに定義されるものである。 $N_i^r$  はノード  $v_i$  に対してエッジ  $r$  で接続されているノードの集合を表している。 $c_{i,r}$  は問題固有の正規化定数であり、学習の際、動的に調整するか、

$c_{i,r} = |N_i^r|$  のように事前に選択する必要がある。 $\sigma$  は活性化関数を表し、今回は ReLU 関数を用いる。

式 (1) で定義されているあるノード  $v_i$  における畳み込みについて考える (図 6)。ノード  $v_i$  における畳み込みは、エッジ  $r$  ごとに固有の重みをかけ

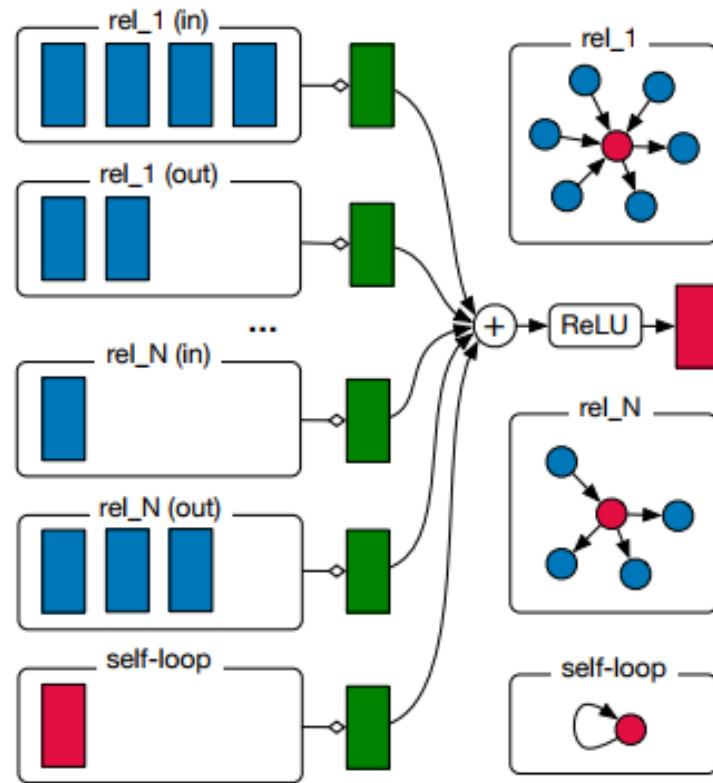


図 6 ノード  $v_i$  における畳み込み

(赤色のブロックがノード  $v_i$  の特徴量、青色のブロックがノード  $v_i$  と接続関係にあるノードの特徴量、緑色のブロックが接続関係にあるノードの特徴量をエッジのラベルごとに変換し、正規化した合計である)

合わせることで行われ、エッジの向き (in、out) によっても区別する。またグラフ  $G$  はマルチグラフであるため、ノード  $v_i$  に足して、同一のノードがエッジ  $r$  の接続関係を複数持つときはその回数分畳み込むものとする。式

(1) に定義されるように、エッジ  $r$  ごとに重みを掛け合わせたうえで正規化済みの合計を計算する (図 6 における緑のブロック)。それを線形結合し、ReLU 関数などの活性化関数を適用し、次の層への入力とする。また同図の最下部にあるようにノード  $v_i$  の特徴量 (赤色のブロック) の保持を目的として、self-loop を定義し、同様に畳み込みを行う。

前述したような畳み込みを複数層にわたって、行うがノード、エッジの数が増えるほどパラメータが増加してしまう関係で、他の深層学習手法より早期の段階で過学習が起こるという問題点が存在する。

R-GCN の二つのタスク (ノード分類とリンク予測) に適応させる際、出力層としてノード分類では SoftMax 関数、リンク予測では DistMult 関数 [5] のようなスコアリング関数を挿入する (図 7)。

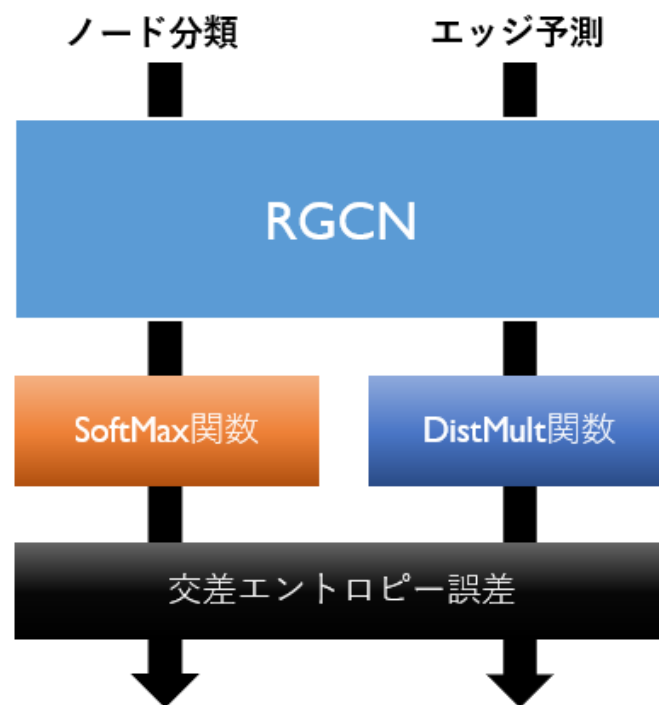


図 7 R-GCN によるノード分類とリンク予測の概要

### 2.1.1 ノード分類

ノード分類を行う際、SoftMax 関数を通して得られた出力に対して交差エントロピー誤差 (式 2) を求め勾配降下法を用いて学習を行う。出力層に用いた SoftMax 関数は、複数の出力の合計を 1 となるように正規化するため、出力をそのまま確率として考えることができ、分類タスクにおける出力層としてよく用いられる。

$$L = - \sum_{i \in Y} \sum_{k=1}^K t_i k \ln h_{ik}^{(L)} \quad (2)$$

式 (2) において、 $Y$  はラベルを持つノードに対するインデックスの集合で  $h$  はインデックス  $i$  を持つラベル付きノードの  $k$  番目の要素を表しており、 $t$  は正解ならば 1、不正解ならば 0 となる正解ラベルである。

### 2.1.2 リンク予測

リンク予測を行う際は、得られた出力に対してノード分類と同様に交差エントロピー誤差 (式 4) を求め勾配降下法を用いて学習を行うが、出力層にスコアリング関数を用いる。またリンク予測の精度はスコアリング関数の性能により変化することが確認されている。

$$f(s, r, o) = e_s^T R_r e_o \quad (3)$$

今回、スコアリング関数として用いる DistMult 関数 [5](式 3) はトリプル  $(s, r, o)$  のつながりの強さを計算することができ、0～1 で表現されるため SoftMax 関数と同様にそのまま確率として考えることができ、リンク予測の精度は、スコアリング関数の性能に依存するため、スコアリング関数の性能向上が R-GCN によるリンク予測の精度向上につながる。得られた出力に

対し、交差エントロピー誤差 (式 4) を求め勾配降下法を用いて学習を行う。

$$L = -\frac{1}{(1+\omega)|\hat{\epsilon}|} \sum_{(s,r,o,y) \in T} y \log l(f(s,r,o)) + (1-y) \log(1-l(f(s,r,o))) \quad (4)$$

存在するトリプル  $(s, r, o)$  をポジティブサンプル、ポジティブサンプルの  $s$ 、 $o$  をランダムに操作し作った存在しないトリプルをネガティブサンプルとし式 (4) において  $T$  はポジティブサンプル、ネガティブサンプルを含むすべてのトリプル  $(s, r, o)$  の集合を表しており、 $y$  はポジティブサンプルなら 1、ネガティブサンプルなら 0 を出力する。 $\omega$  は追加したネガティブサンプルの割合を示し、 $\epsilon$  はポジティブサンプルの集合を表している。

### 3 グラフの定義

今回、サッカーの実試合データとして、StatsBomb(図 8) という企業が Python のライブラリである SoccerAction(図 9) を通して提供している FIFA World Cup の計 64 試合のデータを使用した。試合に出場した選手



図 8 StatsBomb  
(<https://statsbomb.com>)

をポジションとチーム情報を付与したノードとし、パスの出し手と受け手のノードををエッジでつなぎ、さらにボールの所有権チームが変わった際に、最後にボールを保持していた選手とボールを奪取した選手をボールを失ったことを表すエッジでつなぐことで実試合データを 1 つにつなげたグラフを構



図 9 SoccerAction  
(<https://socceraction.readthedocs.io>)

築し (図 10)、それを Normal データとした。




図 10 グラフの定義

(青色が味方、橙色が敵選手を表しており、各ノードは担当ポジションと所属チーム情報を保持する)

また図 11 より、1つのプレーの中でパスが連続でつながる本数には偏りがみられる。よってパスデータの平均化のために Normal データに対してグラフの定義は変えずに少ないパスしかつなぐことのできなかったプレー、またはボールの所有チームが長い間変わらずパスが大量につながったプレーを予測の精度を下げかねない極端なデータと仮定し、削除を行い、その間を




図 11 1つのプレーの中でのパスの連続成功数とその出現回数

詰めたデータ (図 12) を Deleted データとした。これらのデータに対して、R-GCN モデルを適用し、ポジションのノードのラベルとしたノード分類として、パスレシーバーの予測を行う。

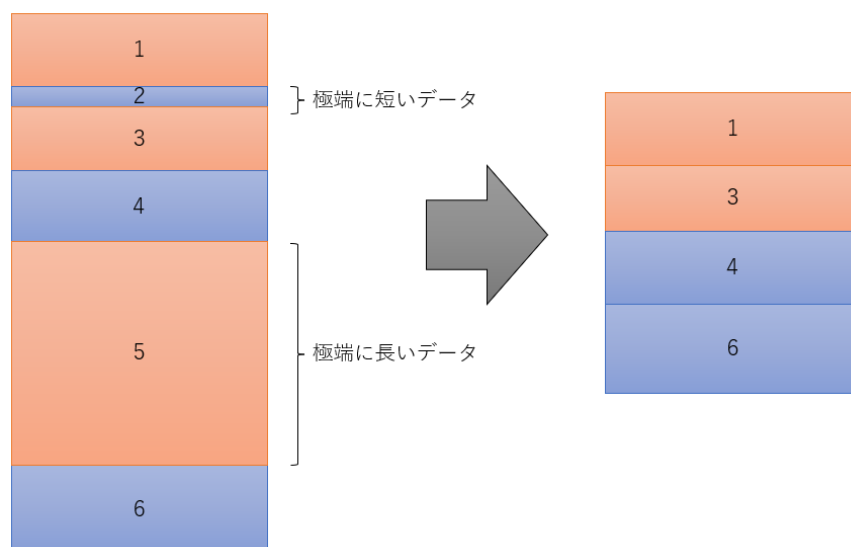


図 12 Deleted データ

(色ごとにチームが分かれており、一つのブロックがボールを失うまでの一連のプレーを表している)

## 4 結果と考察

### 4.1 計 64 試合分のデータを用いた予測

前項で定義したグラフをもとに、FIFA World Cup の計 64 試合のデータを R-GCN モデルに適用し、ノードのラベル分類を行った。ノードのラベルとして SoccerAction 図 9 のデータ内で定義されている以下のポジション 25 個を用い、学習は半教師あり学習で学習データとして決勝戦以外の 63 試合、テストデータとして決勝戦のデータを用いた。

- |                               |                               |
|-------------------------------|-------------------------------|
| 1. Goalkeeper                 | 14. Center Midfield           |
| 2. Right Back                 | 15. Left Center Midfield      |
| 3. Right Center Back          | 16. Left Midfield             |
| 4. Center Back                | 17. Right Wing                |
| 5. Left Center Back           | 18. Right Attacking Midfield  |
| 6. Left Back                  | 19. Center Attacking Midfield |
| 7. Right Wing Back            | 20. Left Attacking Midfield   |
| 8. Left Wing Back             | 21. Left Wing                 |
| 9. Right Defensive Midfield   | 22. Right Center Forward      |
| 10. Center Defensive Midfield | 23. Center Forward            |
| 11. Left Defensive Midfield   | 24. Left Center Forward       |
| 12. Right Midfield            | 25. Secondary Striker         |
| 13. Right Center Midfield     |                               |

分類を行った結果を図 13 に示す。

図 13 より、すべての結果が 6 % 前後となり、まともな予測をすることが



データ名		精度	パスの本数
Normal	—	0.069	51350
Deleted	5~20	0.060	31698
	10~20	0.064	18222
	5~100	0.056	39495
	10~100	0.059	26482

図 13 FIFA World Cup 64 試合分を用いた予測

(Deleted の横の数字は削除しないデータを表す。例えば、5~20 ならば、パスが 5 本未満または 20 本より多くつながったデータを極端なデータとし、削除をする)

できていないことがわかる。原因として、今回用いた 64 試合分のデータをそのままグラフ化することでノード数に対してエッジの数が増えたことが考えられる。これは R-GCN の弱点の一つであり、インターネットにおけるハブのように多くのノードに接続されているノードが複数あると、より広範囲のグラフを畳み込んでしまい、局所的なグラフ固有の特徴量を得られず、予測の精度が著しく低下することが知られている。よって精度を向上させるには、現在よりもノード数を増やし、かつパスの時間的な前後関係情報を保持したグラフデータ構造を取り入れる必要がある。

## 4.2 Spatial Temporal Graph Convolutional Networks のグラフ構造の適用

本項では、前述したような問題点を解決し、精度を向上させるため、Spatial Graph Convolutional Networks(ST-GCN)[4] のグラフデータ構造を参考に

グラフデータ構造の変更を行う。

ST-GCN は Graph Convolution を利用した動作認識手法で、映像から得られる骨格データを二つの要素を用いてグラフ化することで精度を向上させている。二つの要素とは空間グラフと時間グラフであり、あるフレームの骨格における関節の接続関係を空間グラフ、フレーム間の対応する関節同士の接続関係を時間グラフとする。空間グラフ同士の対応する関節ノードを時間グラフとして接続することで空間情報と時間情報を両立させてたグラフを構築する (図 14)。




図 14 ST-GCN の構造

ST-GCN において扱う空間グラフは、関節の接続関係が双方向なものであるため無向グラフであり、今回扱う有向マルチグラフには、モデルをそのまま適応することはできないが、サッカーの実試合データにおいても時間的關係と空間的關係が両立しているため、ST-GCN のグラフデータ構造に注目し、グラフデータ構造の見直しを行う。




図 15 ST-GCN の構造を用いたサッカーの実試合データ

サッカーの実試合データにおいてパスが始まってからボールの所有権が変わるまで区切りとし、空間グラフを構築する。作成した複数の空間グラフに対して、空間グラフ同士の対応するポジションを持つ選手同士をつなぐ時間グラフを構築し (図 15)、立体構造とすることでノード数が増加し、前項で述べたノード数を増やし、かつパスの時間的な前後関係情報を保持したグラフデータ構造を作成した。作成したデータに対して予測を行った結果を図 16 に示す。

図 16 より、全体的に精度が向上したことがわかる。これは前項で述べた問題点が解決し、局所的なグラフの特徴量を得ることができたためと考えることができる。また他のデータセットに比べ、10～20や10～100などの極端に短いデータを削除した場合、精度が高くなっていることがわかる。これはデータの中でも、極端に短いデータの数が多く、分類に必要な特徴量を計算する際にノイズとなっていたためであると考えられる。図 13 の結果と比べ、10倍近い精度となったが十分な精度とは言えないが、原因として、今回分類に用いたラベル数25個は先行研究に比べ多く、さら

データセット		精度	パスの本数
Normal	—	0.530	51350
Deleted	5~20	0.580	31698
	10~20	<b>0.635</b>	18222
	5~100	0.533	39495
	10~100	<b>0.657</b>	26482

図 16 グラフデータ構造変更後の結果

に似た役割を持ち、似た行動をするポジションが存在するため、互いに干渉し、誤分類が起こったためと考えられる。

### 4.3 ラベル数の削減

前項で述べた問題点を解決するため、実試合データにおける選手のポジションを大まかなポジションごとに分類し直すことでラベル数の削減、統合を行い (図 17)、ラベルを 4 つに再分類したデータセットと 8 つに再分類したデータセットを作成した。ラベル数を 4 つとした理由として、R-GCN[2] の性能テストと先行研究 [1] における性能テストは、分類の際ラベル数を 4 ~ 6 程度として行っており、疑似的な性能の比較のためである。またラベル数を 8 つとした理由としては、役割が似ており、同時に存在することの少ないポジションの統合を行った結果である。

ラベル数の削減を行ったデータに対し、ノード分類を行った結果を図 18 に示す。図 18 より、似たポジションを統合することで精度が向上していることがわかる。また図 16 と同様に、ノイズとなっていると思われる極端に

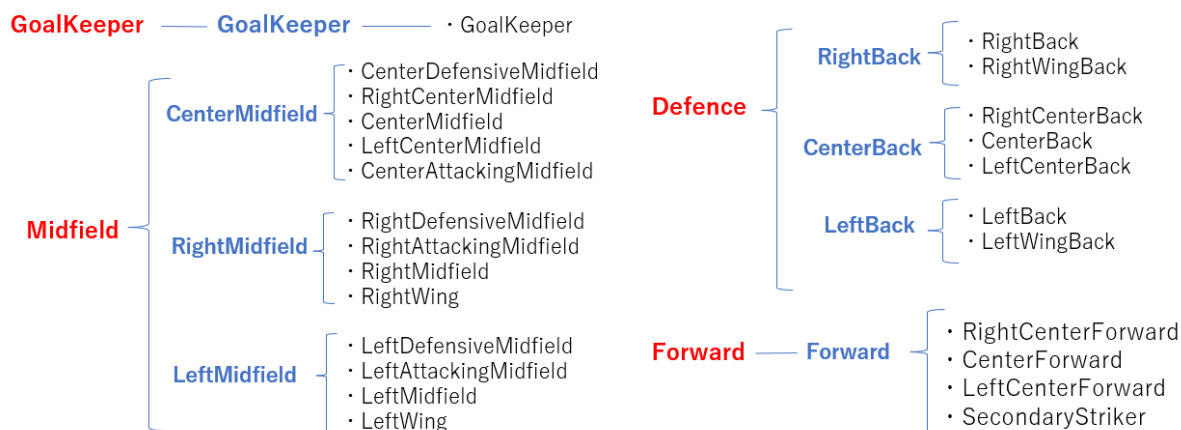


図 17 ラベルの削減

赤色が4つに再分類した際のラベル、青色が8つに再分類した際のラベル

ラベル数 = 4				ラベル数 = 8		
データセット		精度	パスの本数	データセット		精度
Normal	—	0.796	51350	Normal	—	0.700
Deleted	5~20	0.790	31698	Deleted	5~20	0.705
	10~20	<b>0.817</b>	18222		10~20	<b>0.763</b>
	5~100	0.787	39495		5~100	0.746
	10~100	<b>0.834</b>	26482		10~100	<b>0.827</b>

図 18 ラベルの削減後のデータを用いた予測

短いデータを削除した際に精度の向上がみられ、ノイズとなっていることを改めて確認でき、最大で80%を超える結果となった。

## 5 まとめと今後の課題

一般に、統計学の手法を用いて解析されるスポーツの実試合データに対して、Relational-Graph Convolutional Networks[2]を用いた時間情報を含んだパスコースの予測手法を提案し、予測精度は最大で80%を超える結果と

なった。学習時のデータとして、極端に短いデータはノイズとなるため削除することと似た役割を持つポジションラベルを削減、統合することで精度の向上が確認できた。また ST-GCN[4] の構造を模したグラフデータ構造を提案し、それにより精度の向上がみられたが、あくまでも 1 手法であり、今後もグラフデータ構造の検討が必要である。

## 謝辞

本研究を行い、本論文を執筆するにあたり、指導教員として、他大学の教授としてお忙しい中、時間をお作りいただき、多大なご指導をいただいた井上茂雄先生に深く感謝いたします。また大学院進学後の指導教員として、他研究室にも関わらず、細かなアドバイスを賜りましたネットワーク応用研究室の藤井章博先生につきましても深く感謝申し上げます。

## 参考文献

- [1] 糸田 孝太, 渡邊 紀文, 武藤 佳恭, 実試合データに基づくサッカーエージェントのパスレシーバー選択モデルの構築, Journal of Japan Society for Fuzzy Theory and Intelligent Informatics, 2014;26(3):678-687.
- [2] Schlichtkrull, M., Kipf, T. N., Bloem, P., van den Berg, R., Titov, I. and Welling, M., Modeling Relational Data with Graph Convolutional Networks, pp. 593-607, in Aldo Gangemi et al (eds.), ESWC 2018: The Semantic Web, Springer, 2018 (Lecture Notes in Computer Science, vol. 10843).
- [3] Girshick, R., Donahue, J., Darrell, T., Malik, J. (2014). Rich feature hierarchies for accurate object detection and semantic segmentation.

Paper presented at the Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 580-587.  
doi:10.1109/CVPR.2014.81 Retrieved from [www.scopus.com](http://www.scopus.com)

- [4] S. Yan, et al., “Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition” , AAAI, 2018.
- [5] Yang, B., Yih, W. T., He, X., Gao, J., and Deng, L. (2014). Learning multi-relational semantics using neural-embedding models. arXiv preprint [arXiv:1411.4072](https://arxiv.org/abs/1411.4072).

## 付録

今回実装したソースコード

<https://github.com/Taiki-4be/paper-ver.git>